THIRUMURUGAN KUMAR

Paris, France | +33 6 05 52 73 58 | rishithiru1998@gmail.com
thiruuportfolio.netlify.app | github.com/thirurishi | linkedin.com/in/thirumurugan-kumar-a63792251

Étudiant en Master Data Science & Analytics à l'EPITA, **disponible immédiatement pour un stage de fin d'études de 6 mois** (Data Analyst, Data Scientist, BI ou IA). Expérience projet sur l'ensemble du cycle de la donnée : analyse SQL et Python, tableaux de bord Power BI, pipelines de qualité des données, machine learning et applications NLP et RAG/LLM déployées.

Formation

Master en informatique – Data Science & Analytics, EPITA, Paris, France 2024 – 2026
Bachelor en technologies de l'information, St. Joseph's College of Engineering, Chennai, Inde 2020 – 2024

Projets

Analyse du réachat client (Repeat Purchase Recovery) GitHub *SQL, SQLite, Python, pandas, Power BI*

- Construction d'un pipeline SQL en six couches (20 vues SQLite, 63 requêtes de validation) sur 93 358 clients et 96 478 commandes livrées : rétention par cohorte, valeur vie client, segmentation et signaux de churn.
- Taux de réachat de 3,0 % et délai médian de retour de 29 jours ; les premières commandes d'un seul article (90 % des clients) donnent 2,15 % de réachat contre 5,38 % pour les paniers de 6 articles et plus.
- Recommandation de trois actions de rétention priorisées ; un modèle de scénarios estime ∼928 clients récurrents supplémentaires (+33 %) (hypothèses explicites).

Analyseur IA CV / offre d'emploi Démo | GitHub *Python, Streamlit, scikit-learn, PyMuPDF, SQLite, Pytest*

- Conception et déploiement d'une application web NLP qui analyse les CV au format PDF et calcule un score ATS explicable (50 % compétences, 30 % similarité sémantique TF-IDF, 20 % complétude du CV).
- Génère en moins de 5 secondes l'analyse des compétences manquantes, des recommandations de type recruteur, une lettre de motivation et un message LinkedIn ; tests Pytest et historique SQLite.

Détection de fake news (RAG/LLM) *PyTorch, TensorFlow, LangChain, FAISS, FastAPI, PostgreSQL*

- Plateforme full-stack de fact-checking classant des affirmations avec un ensemble de modèles LSTM, GRU et TextCNN entraînés sur le jeu de données LIAR.
- Couche d'explicabilité combinant web scraping, score de pertinence BERT, recherche de similarité FAISS et justifications générées par LLM (LangChain, Groq) ; FastAPI (JWT), PostgreSQL, Docker Compose.

Système de prédiction de l'attrition des employés *Python, scikit-learn, Airflow, FastAPI, Docker*

- Système ML de bout en bout : ingestion Airflow, contrôles qualité Great Expectations séparant données valides et invalides, stockage PostgreSQL et classifieur Random Forest (F1 de 0,85 sur données synthétiques).
- Prédictions unitaires et par lot via FastAPI et Streamlit, avec supervision Grafana, alertes Microsoft Teams et déploiement Docker Compose.

Business Intelligence & rentabilité retail GitHub *SQL, SQLite, Power BI, DAX, Power Query*

- Conception d'un rapport Power BI de deux pages sur un modèle en étoile (1 table de faits, 4 dimensions) avec six mesures DAX, analysant 10 194 lignes de ventes sur 5 111 commandes (2,33 M de CA, marge de 12,56 %).
- Rédaction de quatre analyses SQL de rentabilité par catégorie, produit et niveau de remise, rapprochées des mesures Power BI, identifiant les produits déficitaires.

Expérience

Stagiaire développeur Android – National Small Industries Corporation (NSIC) Décembre 2022

- Développement d'une application Android de tourisme tout-en-un : guides de destinations, meilleure saison pour voyager, lieux incontournables et recommandations de restaurants.
- Création d'une fonctionnalité de recherche et de comparaison de vols, similaire à Google Flights, pour trouver les tarifs les moins chers ; travail structuré en développement, tests et documentation.

Compétences

- **Analyse de données & BI :** SQL, Python (pandas, NumPy), Power BI, DAX, Power Query, Excel (avancé), Matplotlib, Seaborn ; analyse de KPI, de cohortes et de rétention
- **Machine learning & NLP :** scikit-learn, TensorFlow, PyTorch, Hugging Face Transformers, LSTM, GRU, TextCNN, TF-IDF ; RAG avec LangChain et FAISS
- **Data engineering & déploiement :** PostgreSQL, SQLite, Apache Airflow, Great Expectations, FastAPI, Docker Compose, Streamlit, Grafana
- **Outils :** Git, GitHub, Jupyter, Pytest, développement Android

Langues

Anglais (courant) | Français (niveau professionnel) | Tamoul (langue maternelle) | Hindi (intermédiaire)